분석 소개

첫 구매 이후, 고객은 다시 구매할까?

H&M 구매 데이터로 살펴본 30 일 재구매 특성

김진서 | 데이터 분석 개인 프로젝트
사용 도구: Python · pandas · Matplotlib

https://github.com/jinseo9797/hm-repurchase-analysis

분석 코드 01~10 과 결과 자료는 GitHub 저장소에 정리했습니다. 실제 분석은 Python 으로 수행했으며, SQL 주석은 참고용 예시입니다.

왜 이 분석을 했나요?

패션 커머스에서는 한 번 구매한 고객이 다시 구매하는지 살펴보는 것이 중요합니다. 구매 이후의 행동을 이해하면 고객에게 언제, 어떤 방식으로 다시 서비스를 안내할지 가설을 세울 수 있습니다.

확인한 질문

① 처음 구매가 관측된 고객 중 30 일 안에 다시 구매한 비율은 얼마일까?
② 처음 구매가 관측된 월에 따라 차이가 있을까?
③ 첫 구매일에 이용한 채널에 따라 차이가 있을까?

분석 규모	핵심 결과
거래 31,788,324 행	전체 30 일 재구매율 28.13%
분석 고객 1,338,029 명	월·채널별로 재구매율 차이 확인

이 프로젝트에서 보여주고자 한 역량

많은 데이터를 나누어 처리하고, 지표의 기준을 정한 뒤, 결과가 이상해 보이면 원본과 대조했습니다. QA 에서 쌓은 데이터 검증 경험을 분석 과정에 연결했습니다.

H&M 공개 구매 데이터로 진행한 독립적인 개인 분석입니다. 다른 서비스의 고객이나 운영 성과로 일반화할 수 없습니다.

데이터와 기준

비교하기 전에, 같은 기준으로 계산했습니다

사용 데이터: Kaggle H&M Personalized Fashion Recommendations 의 transactions_train.csv, customers.csv, articles.csv
거래 관측 기간: 2018.09.20~2020.09.22

30 일 재구매율을 어떻게 계산했나요?

첫 관측 구매일 다음 날부터 30 일째까지
다시 구매한 고객 수 ÷ 분석 대상 고객 수 × 100

예를 들어 5 월 1 일에 처음 구매가 관측된 고객은 5 월 2~31 일에 구매했으면 재구매 고객으로 분류했습니다. 첫날 상품을 여러 개 구매한 것은 재구매로 세지 않았습니다.

기준	처리 방법
첫 관측 구매	고객별로 데이터에 처음 등장한 구매 날짜
충분한 관찰 기간	첫 구매일이 2020.08.23 까지인 고객만 포함
고객 단위 계산	한 고객이 여러 번 재구매해도 한 명으로 계산
거래 행의 의미	주문 ID 가 없으므로 거래 행 수와 주문 수를 구분

계산 전에 확인한 항목

거래의 결측치·날짜·가격 오류를 확인하고, 고객·상품 ID 의 중복과 거래 데이터의 연결 관계를 점검했습니다. 약 3.4GB 의 거래 CSV 는 10 만 행씩 나누어 처리했습니다.

거래에 등장한 고객 1,362,281 명 중 30 일을 관찰할 수 없는 24,252 명을 제외해, 최종 1,338,029 명을 분석했습니다.

데이터 시작 이전의 구매 이력은 알 수 없습니다. 따라서 “첫 관측 구매 고객”을 실제 신규 고객이라고 해석하지 않았습니다.

결과 01 · 기간별 비교

전체 평균은 고객 구성에 따라 달라졌습니다

전체 30 일 재구매율은 28.13%였습니다.

분석 대상	고객 수	재구매율
전체 분석 대상	1,338,029 명	28.13%
2018 년 9 월 첫 관측 고객 제외	1,197,689 명	26.15%
2019 년 이후 첫 관측 고객	756,843 명	21.81%

쉽게 설명하면

같은 방식으로 계산해도 어떤 시기의 고객을 포함하는지에 따라 결과가 달라졌습니다. 2019 년 이후에 처음 등장한 고객만 보면 전체보다 6.32%p 낮았습니다. 21.81%가 더 정확한 정답이라는 뜻은 아닙니다.

왜 이런 차이가 있을까요?

데이터 초반에는 이전부터 구매하던 고객이 처음 등장한 고객으로 포함됐을 수 있습니다. 계절이나 고객 구성의 차이도 가능하므로 한 가지 원인으로 단정하지 않았습니다.

첫 관측 구매 월	30 일 재구매율
2018 년 9 월	45.03%
2018 년 10 월	38.08%
2018 년 11 월	31.24%

분석에서 얻은 교훈

전체 평균 하나만 보면 고객군의 차이를 놓칠 수 있습니다. 재구매율을 보고할 때는 분석 대상과 기간을 함께 설명하고, 처음 구매한 시기가 비슷한 고객끼리도 비교해야 합니다.

월별 첫 관측 고객 수는 그 월의 전체 구매 고객 수와 다릅니다. 이 결과만으로 전체 이용 고객이나 매출이 감소했다고 판단할 수 없습니다.

결과 02 · 채널별 비교

채널별 차이를 보고, 원본 데이터로 한 번 더 확인했습니다

첫 관측 구매일에 사용한 채널로 고객을 나눴습니다. 같은 날 두 채널을 사용한 고객은 별도 그룹으로 분류했습니다. 채널의 실제 의미는 확인하지 않아 번호로 표시했습니다.

첫 구매일 이용 채널	고객 수	재구매율
채널 1 만 이용	460,403 명	29.87%
채널 2 만 이용	870,512 명	27.04%
두 채널 모두 이용	7,114 명	48.62%

채널 1 고객군은 채널 2 보다 2.83%p 높았습니다. 두 채널 이용 고객군은 가장 높았지만 전체의 약 0.53%입니다. 원래 구매 활동이 활발한 고객일 수도 있어 채널 이용의 효과로 단정하지 않았습니다.

검증 사례: 4 월에는 왜 채널 1 고객이 없었을까요?

2020 년 4 월 첫 관측 고객이 모두 채널 2 로 분류되어, 기존 고객을 포함한 원본 거래도 월·채널별로 다시 세었습니다.

월	채널 1 거래 행 수	채널 2 거래 행 수
2020 년 3 월	154,087	893,665
2020 년 4 월	0	1,340,882
2020 년 5 월	391,746	970,069

원본에서도 4 월 채널 1 거래는 0 행이었습니다. 고객 분류 결과와 원본의 분포가 일치함을 확인했습니다. 다만 거래가 관측되지 않은 배경까지는 이 데이터로 확정할 수 없습니다.

채널별 수치는 전체 기간을 합친 결과입니다. 시기나 고객 특성의 영향을 분리한 채널 자체의 효과를 의미하지 않습니다.

활용 제안과 회고

분석 결과를 작은 실험으로 연결하겠습니다

향후 검증해볼 가설

첫 관측 구매 후 아직 재구매하지 않은 고객에게 추천 메시지를 보내면 재구매율이 달라질까요? 아래는 향후 서비스에서 검증할 수 있는 실험 설계안입니다.

항목	실험 제안 — 실행하지 않은 계획
대상	첫 구매 후 7 일 동안 재구매하지 않은 메시지 수신 동의 고객
방법	대상 고객을 무작위로 두 그룹에 배정
실험군 / 비교군	추가 추천 메시지 발송 / 추가 메시지 미발송
주요 지표	배정 고객 중 첫 구매 후 30 일까지 재구매한 고객 비율
함께 볼 지표	메시지 수신 거부율, 고객당 구매 금액

두 그룹의 관찰 기간과 다른 운영 조건을 맞추고 결과를 비교합니다. 7 일이라는 시점과 추천 메시지의 효과는 이번 분석으로 입증한 내용이 아니라, 앞으로 검증할 가설입니다.

이 분석의 한계

데이터 시작 전 구매 이력을 알 수 없어 실제 신규 고객을 구분할 수 없습니다. 채널별 차이에도 관측 시기와 고객 구성이 영향을 주었을 수 있습니다. 따라서 재구매율 차이를 특정 채널의 효과로 해석하지 않았습니다.

배운 점

지표를 계산하는 것만큼 누구를 어떤 기준으로 비교했는지 설명하는 일이 중요했습니다. 예상과 다른 결과가 나오면 원본을 확인하고, 확인한 사실과 추측을 구분하는 습관을 익혔습니다.

결과 근거: 직접 실행한 Python 분석의 출력과 집계 결과. 원본 출처: Kaggle · H&M Personalized Fashion Recommendations. 본 문서는 분석 결과 요약이며, 실험 성과를 주장하지 않습니다.

https://github.com/jinseo9797/hm-repurchase-analysis